Data-Driven Knowledge Graph com LLM

Disciplina

TÓPICOS ESPECIAIS EM PROCESSAMENTO INTELIGENTE DA INFORMAÇÃO — PPGEEC2327

Professor

Ivanovitch Medeiros Dantas da Silva

Discentes

Marília Muniz, Larissa Kelmer e Samuel Amico

Problemas e Soluções

LIMITAÇÕES DOS LLMs

Principais Desafios:

- Limitação da base de treinamento
- Informação defasada
- Hallucinations (Alucinações)

ESTRATÉGIAS DE MITIGAÇÃO

Abordagens Técnicas:

- Fine-tuning
- Retrieval-Augmented Generation (RAG)
- Agents (tools)

Objetivo do Trabalho

- Superar a limitação temporal (Knowledge Cutoff).
- Estruturar os dados não-estruturados.
- Otimizar do RAG tradicional.
- Reduzir de alucinações.

Metodologia do Trabalho

1. Triagem Literária

Mapeamento inicial de 5 artigos chave sobre orquestração de Agentes LLM.

2. Seleção Crítica

Filtragem dos 3 estudos com maior aderência técnica ao contexto do projeto.

3. Sintonia de Dados

Conexão semântica das informações para criar uma base de conhecimento unificada.

4. Implementação RAG

Integração em pipeline RAG para viabilizar pesquisas centradas e precisas.

Ferramentas

- EdgeQuake - DataDriven
- GraphRag (Microsoft)
- Graphify

Dados

STELLAR: A Structured, Trustworthy, and Explainable LLM-Led Architecture for Reliable Customer Support

Objetivos:

- Superar as limitações de LLMs, como alucinações, falta de consistência e falta de rastreabilidade.

- Projetar um sistema para automatizar o suporte ao cliente, validado no domínio de seguros.

Metodologia:

- Arquitetura em DAG: loops finitos e previsibilidade.
- 9 Módulos especializados e 11 fluxos predefinidos.
- Usa few-shot, RAGs híbridas, human-in-the-loop e verificações de ética e conformidade.

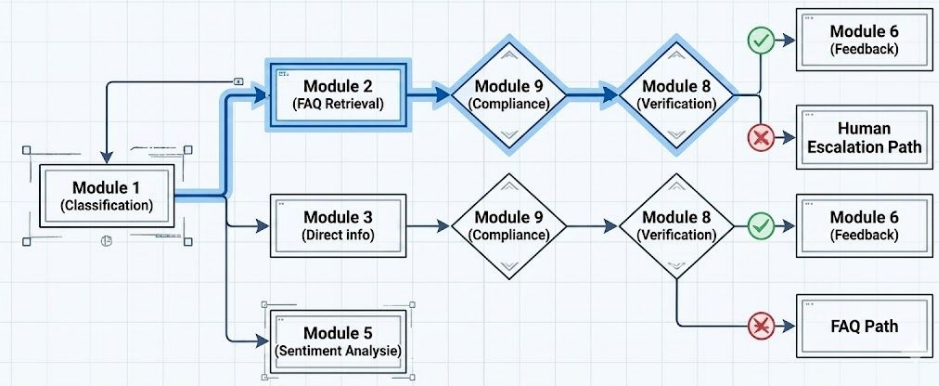

Resultados:

- Confiabilidade em tarefas críticas, com 97% de precisão em classificação de consultas.

- Estratégia de recuperação híbrida e rerank (HS+R).

- Prova viabilidade do uso de LLMs em sistemas com restrições rigorosas.

Dados

TickIt: Leveraging Large Language Models for Automated Ticket Escalation

Objetivos:

- Automatizar eaprimorar a precisão no escalonamento de tickets de suporte em sistemas de serviço em nuvem de grande escala.

- Resolver as deficiências de análises estatísticas, abordando a natureza das reclamações e incidentes relatados por clientes.

Metodologia:

- Análise contínua online.
- Classificação multiclasses com CoT e compara embeddings para evitar deduplicação.
- Otimização contínua com SFT guiado por categoria e com avaliação dos analistas (human-in-the-loop).

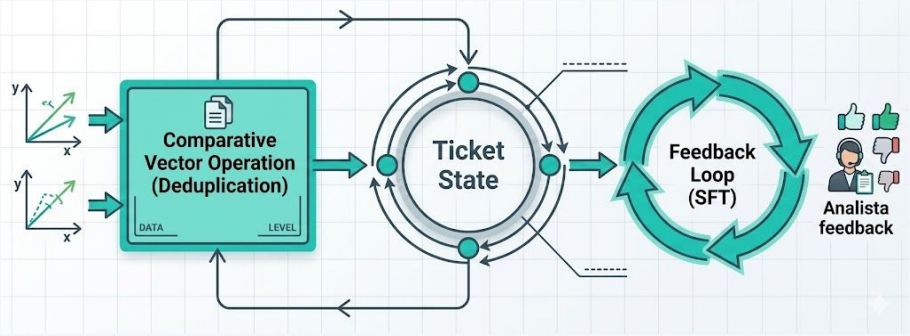

Resultados:

- Redução de 39% do MTTR de incidentes críticos.

- O sistema alcançou um F1 score de 86,2% em avaliações de escalonamento.

- Aumento da eficiência operacional.

Dados

LLM Agents for Smart City Management: Enhancing Decision Support Through Multi-Agent AI Systems

Objetivos:

- Melhorar o processo de tomada de decisõesestratégicas na gestão urbana.

- Investigar a eficácia da união entre LLMs e sistemas operacionais complexos de informações urbanas.

Metodologia:

- Arquitetura multiagente hierárquica.
- Combina o uso de RAG com chamadas a APIs de serviços da cidade.
- Foi testado contra 150 consultas complexas.

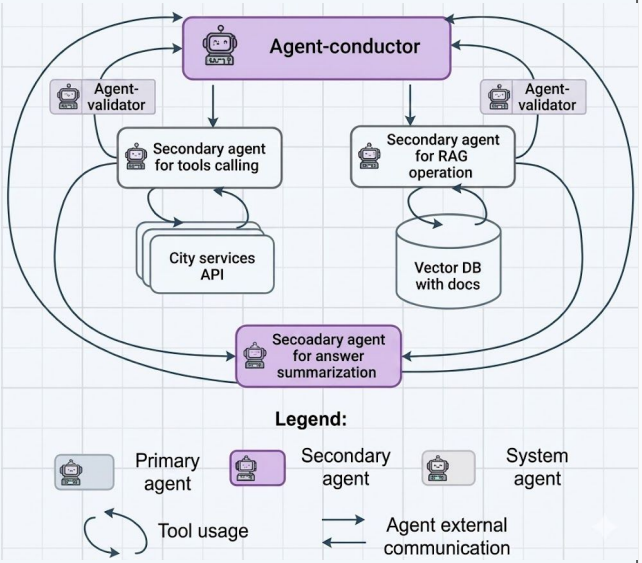

Resultados:

- Precisão de 94%-99% no roteamento de agentes.

- A integração RAG+APIs melhorou 0.68-0.74 em pontuação G-Eval.

- Redução no tempo de conclusão de tarefas, mantendo a precisão.

Visão Geral - Edge Quake

Documentos: 3
Entidades: 2062
Relações: 5511

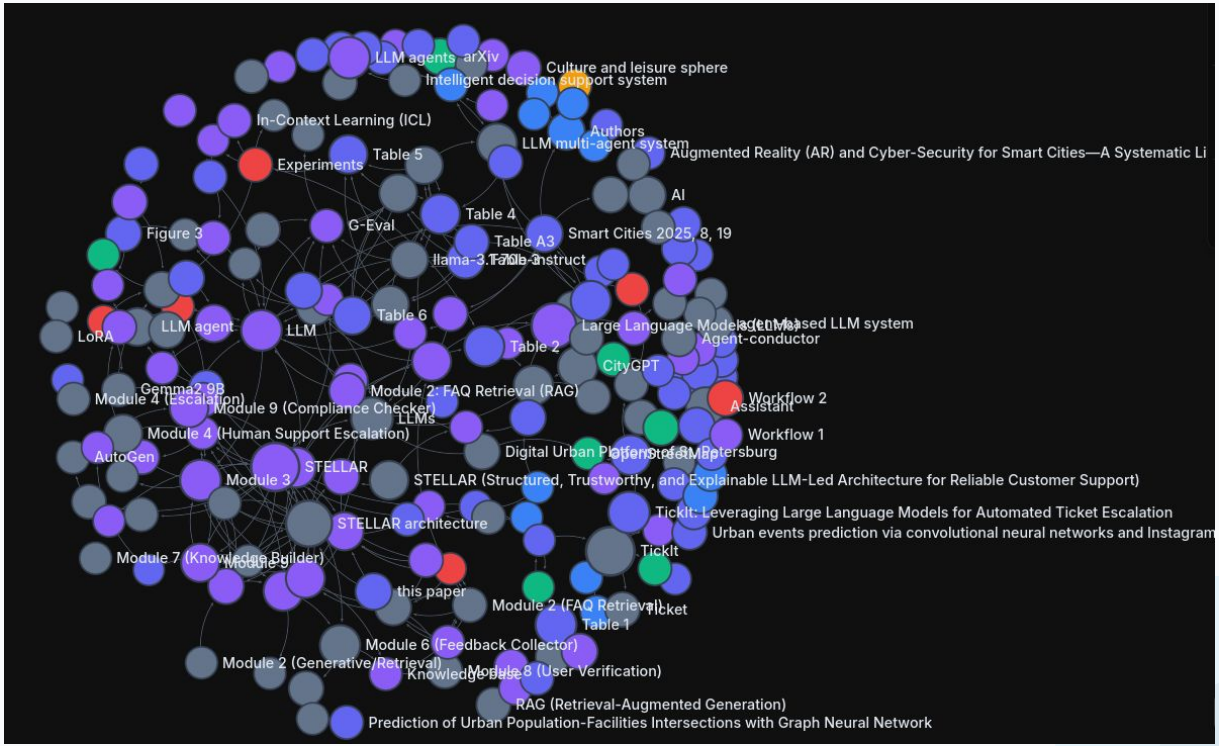

Figura 1:knowledge graph . Fonte: print do Edge Quake(Versão de Abril/2026)

Visão Geral - GraphRag

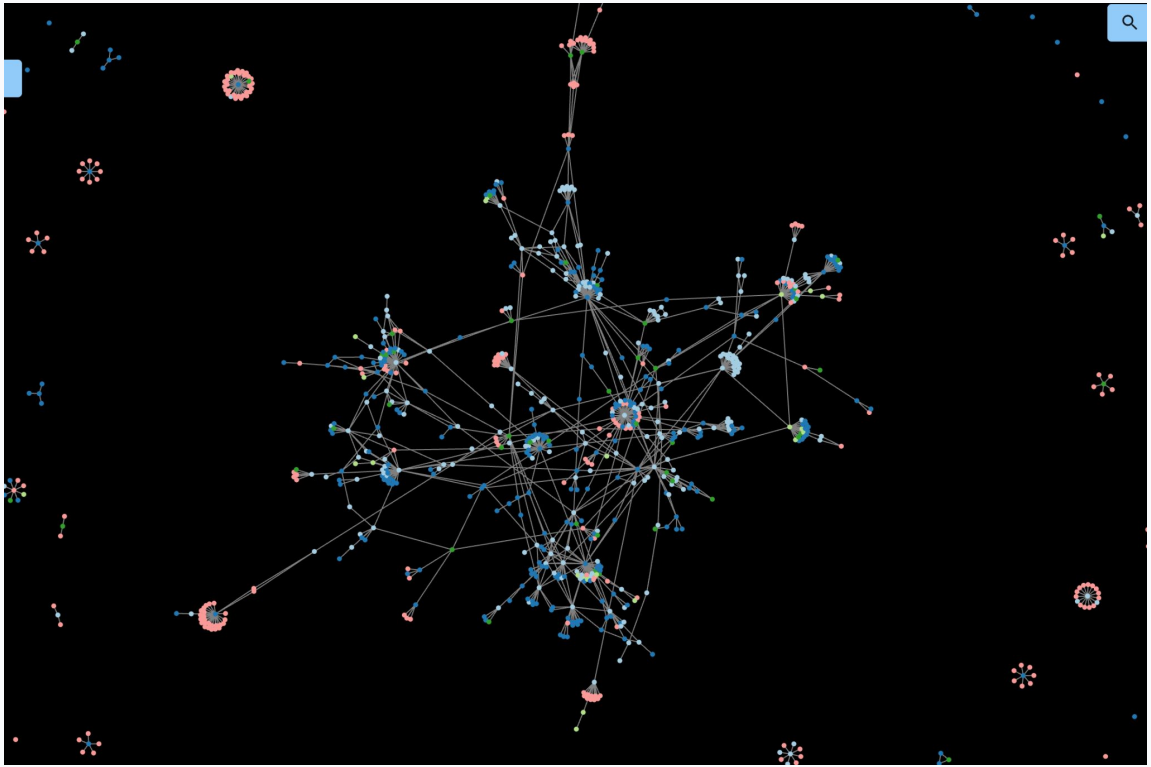

Figura 2: knowledge graph . Fonte: https://noworneverev.github.io/graphrag-visualizer/#/graph (Versão de Abril/2026)

Processamento (Graphify)

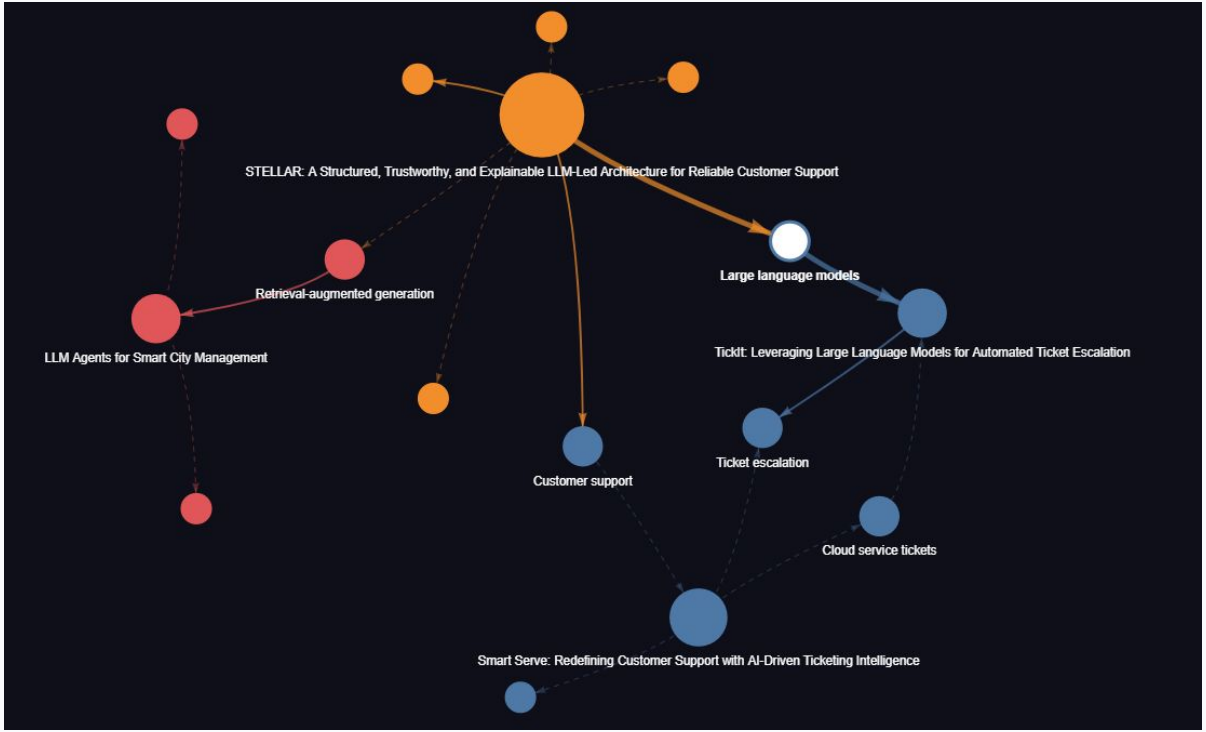

Figura 5: Graphify. Fonte: Larissa - modelo Cloude (Versão de Abril/2026)

Visão Geral - Notebook LM

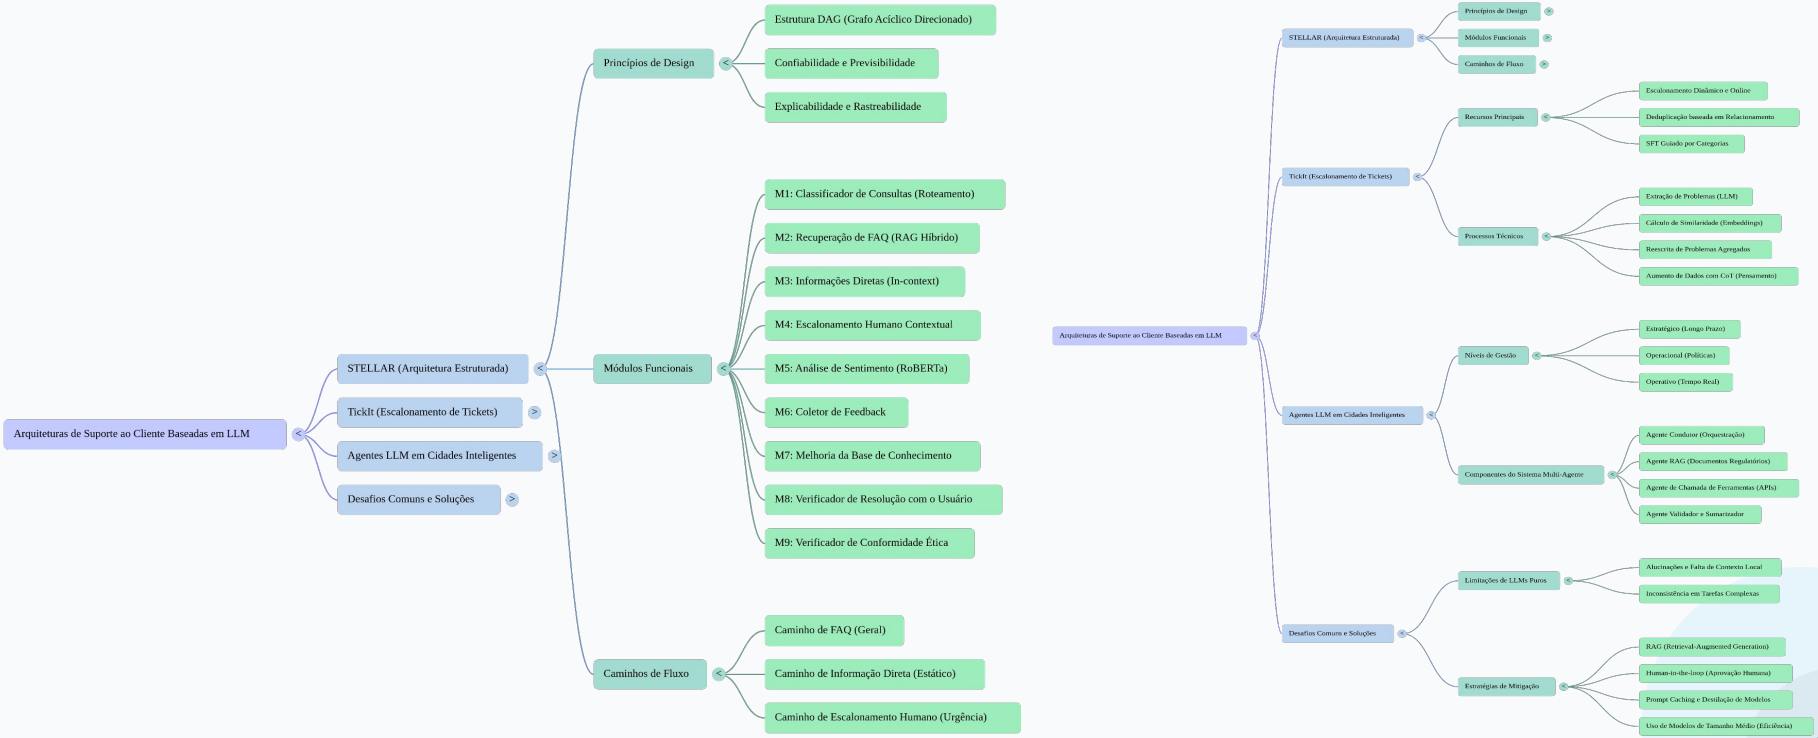

Figura 3: Mapa mental. Fonte: Elaborado pelos autores com auxílio do NotebookLM (Versão de Abril/2026)

Processamento (GraphRag)

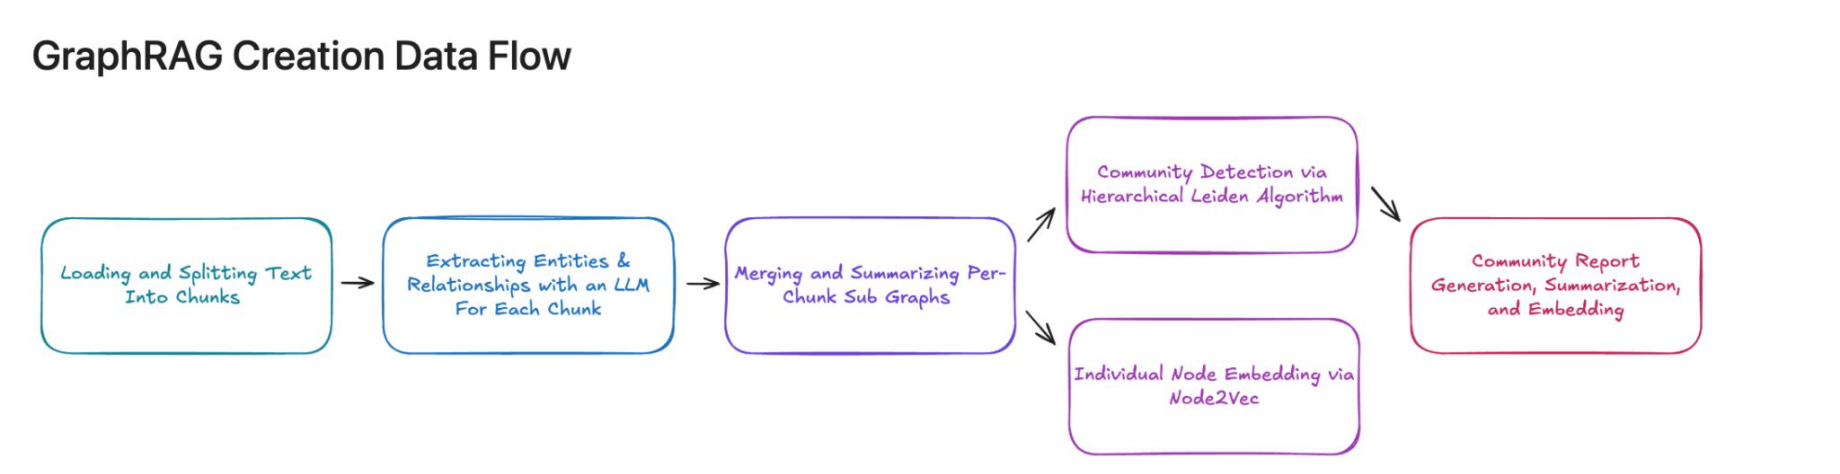

Figura 3: Microsoft KG Flow. Fonte: Microsoft (Versão de Abril/2026)

Processamento (GraphRag)

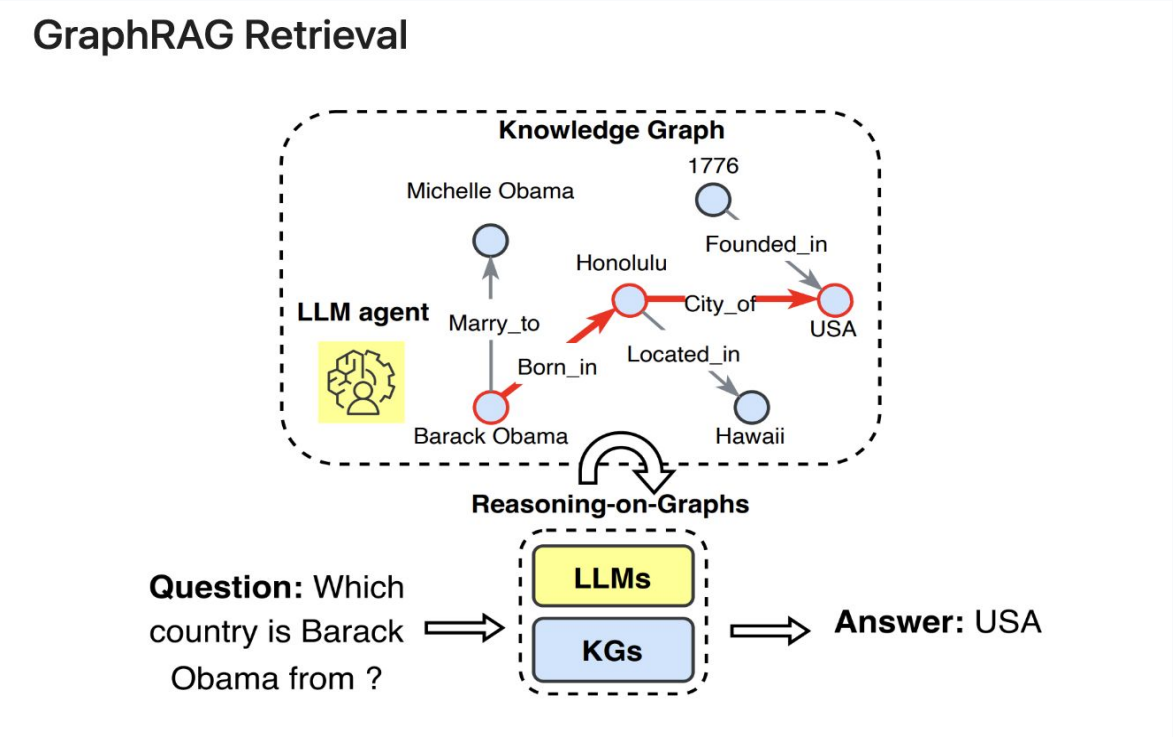

Figura 4: Microsoft Query Flow. Fonte: Microsoft (Versão de Abril/2026)

Processamento (GraphRag)

-Goal-
Given a text document that is potentially relevant to this activity and a list of entity types, identify all entities of those types from the text and all relationships among the identified entities.

-Steps-
1. Identify all entities. For each identified entity, extract the following information:
- entity_name: Name of the entity, capitalized
- entity_type: One of the following types: [large language model, differential privacy, federated learning, healthcare, adversarial training, security measures, open-source tool, dataset, learning rate, AdaGrad, RMSprop, adapter architecture, LoRA, API, model support, evaluation metrics, deployment, Python library, hardware accelerators, hyperparameters, data preprocessing, data imbalance, GPU-based deployment, distributed inference]
- entity_description: Comprehensive description of the entity's attributes and activities
Format each entity as ("entity"{{tuple_delimiter}}<entity_name>{{tuple_delimiter}}<entity_type>{{tuple_delimiter}}<entity_description>)

2. From the entities identified in step 1, identify all pairs of (source_entity, target_entity) that are *clearly related* to each other.
For each pair of related entities, extract the following information:
- source_entity: name of the source entity, as identified in step 1
- target_entity: name of the target entity, as identified in step 1
- relationship_description: explanation as to why you think the source entity and the target entity are related to each other
- relationship_strength: an integer score between 1 to 10, indicating strength of the relationship between the source entity and target entity
Format each relationship as
("relationship"{{tuple_delimiter}}<source_entity>{{tuple_delimiter}}<target_entity>{{tuple_delimiter}}<relationship_description>{{tuple_delimiter}}<relationship_strength>)

Figura 6: Microsoft KG Prompt. Fonte: Microsoft (Versão de Abril/2026)

Processamento (GraphRag)

Node Details: HIT-RATE@N

Node Information

ID: 81f5505f-c343-4562-ab19-55762e04e444
Title: HIT-RATE@N
Type:
Community Report Title: HIT-RATE@N
Human Readable ID: 62

Linked Nodes

id	human_readable_id	title	type	description	text_
035f2bd4-c0de-4b2f-b814-6ca5b2a74977	58	RECALL@N	EVENT	Recall@n is a metric that indicates the average proportion of a query's relevant FAQs retrieved within the top n results.	["03a
db379b24-de61-4f67-be77-fbd27b0c9162	59	MEAN RECIPROCAL RANK	EVENT	Mean Reciprocal Rank (MRR) is a metric that calculates the average reciprocal rank of the first relevant FAQ retrieved.	["03a

Rows per page 10 1-2 of 2

Linked Relationships

source	target	type	weight	description	text_unit_ids
RECALL@N	HIT-RATE@N	RELATED	6	Both Hit-Rate@n and Recall@n are metrics used to evaluate the performance of retrieval systems	["03a33b7b072a8aae200487924d3
MEAN RECIPROCAL RANK	HIT-RATE@N	RELATED	6	Mean Reciprocal Rank is another metric that complements Hit-Rate@n in evaluating retrieval performance	["03a33b7b072a8aae200487924d3

Figura 7: GraphRag API. Fonte: API swagger (Versão de Abril/2026)

Processamento (GraphRag)

Node Details: ACIIS

Node Information

ID: 3c6db168-48b9-464f-81d9-c3e9b6d1cede
Title: ACIIS
Type: EVENT
Community Report Title: ACIIS
Description: The 6th International Conference on Applied Computational Intelligence in Information Systems is an event that discusses advancements in computational intelligence applied to urban systems.
Human Readable ID: 1139

Linked Nodes

id	human_readable_id	title	type	description
98983afd-e24f-48ae-a16a-99ed43a44f3c	1138	BANDAR SERI BEGAWAN	GEO	Bandar Seri Begawan is the capital city of Brunei, where the 2023 6th International Conference on Applied Computational Intelli
f55195cd-c6e1-443c-a613-91e5e5293e61	1142	ZHANG, W.	PERSON	W. Zhang is an author contributing to the research on Urban Foundation Models presented at the ACM SIGKDD Conference.
e8c20586-d210-4950-919f-3fec46cf4c2b	1143	HAN, J.	PERSON	J. Han is an author contributing to the research on Urban Foundation Models presented at the ACM SIGKDD Conference.
5dc7a28a-0483-4e74-9442-4292618b1f4f	1144	XU, Z.	PERSON	Z. Xu is an author contributing to the research on Urban Foundation Models presented at the ACM SIGKDD Conference.
de6f1ee3-7e51-45e3-926e-4bd7d55064c7	1145	NI, H.	PERSON	H. Ni is an author contributing to the research on Urban Foundation Models presented at the ACM SIGKDD Conference.
ce8e8bac-9ea7-4f66-a326-22c0f705c83d	1146	LIU, H.	PERSON	H. Liu is an author contributing to the research on Urban Foundation Models presented at the ACM SIGKDD Conference.
94a2e145-e35e-492e-bcb5-039cce1c6872	1147	XIONG, H.	PERSON	H. Xiong is an author contributing to the research on Urban Foundation Models presented at the ACM SIGKDD Conference.
50526fe1-e848-426f-b8ef-f0a34e263406	1165	MUKHINA, K.		
c4199933-a44e-433d-b35d-8995af94cb5b	1148	VISHERATIN, A.	PERSON	A. Visheratin is an author who contributed to the research on urban events prediction via convolutional neural networks and Ins
a64c2b9e-30ff-417e-abb3-851a0baa60c4	1149	NASONOV, D.	PERSON	D. Nasonov is an author who contributed to the research on urban events prediction via convolutional neural networks and Insta

Figura 8: GraphRag API. Fonte: API swagger (Versão de Abril/2026)

Metodologia do Trabalho

- **Prompts de test:**

QUESTION: What are the main limitations of standalone LLMs in customer support?

QUESTION: How does the STELLAR architecture improve reliability?

QUESTION: What is the role of RAG in the STELLAR system?

QUESTION: What are the benefits of conversational agents in education?

Resultados

QUESTION: What are the main limitations of standalone LLMs in customer support?

Comparativo de Ferramentas de RAG

Limitações de LLMs standalone em customer support

Parâmetro	Edge Quake	Notebook LM	Graphify	ChromaDB
Paradigma	RAG sobre corpus	RAG com citações	RAG sobre grafo	RAG vetorial puro
Rastreabilidade	●●○○ 2/4	●●●● 4/4	●●●○ 3/4	●○○○ 1/4
Ancoragem no corpus	●●●○ 3/4	●●●○ 3/4	●●●● 4/4	●○○○ 1/4
Profundidade técnica	●●●● 4/4	●●●○ 3/4	●●○○ 2/4	●●○○ 2/4
Risco de alucinação	Baixo	Muito baixo	Baixo	Médio
Caso de uso ideal	Análise técnica detalhada	Pesquisa com citação verificável	Mapa de domínio e relações	Resumo rápido e genérico

● *Notebook LM: melhor para citação* · ● *Edge Quake: melhor para análise técnica* · ● *Graphify: melhor para visão estrutural* · ● *ChromaDB: rápido, mas com perda de ancoragem*

Figura 9: Tabela comparativa das ferramentas (Versão de Abril/2026)

Resultados (ChormaDB)

As principais limitações dos LLMs autônomos no suporte ao cliente incluem:

1. **Consistência**: Os LLMs podem ter dificuldade em fornecer respostas consistentes ao longo do tempo, o que pode causar confusão nos clientes.
2. **Confiabilidade Factual**: Eles são suscetíveis a gerar informações incorretas ou enganosas, fenômeno frequentemente chamado de "alucinação".
3. **Explicabilidade**: Os LLMs podem carecer de transparência sobre como chegam a certas respostas, dificultando a compreensão do raciocínio por trás delas pelos usuários.
4. **Manutenção de Contexto**: Eles podem ter dificuldade em manter o contexto em interações longas, o que é crucial para um suporte ao cliente eficaz.
5. **Raciocínio Complexo**: Os LLMs podem não executar de forma confiável processos de raciocínio complexos e de várias etapas, frequentemente exigidos em cenários de suporte.
6. **Gerenciamento de Diálogos Multiturnos**: Eles podem ter dificuldade em gerenciar de forma fluida diálogos complexos com várias interações, o que pode prejudicar a qualidade do atendimento.

Resultados (EdgeQuake)

1. Confiabilidade e Veracidade

- **Alucinações:** Suscetibilidade a gerar respostas plausíveis, porém incorretas, comprometendo decisões e o atendimento confiável.
- **Inconsistência Factual:** Garantia limitada de precisão quando o modelo opera sozinho, sem mecanismos de checagem externa.
- **Obsolescência:** Modelos "congelados" podem não refletir regras, normas ou dados locais atualizados, falhando em substituir sistemas de domínio integrados.

2. Raciocínio e Operação

- **Raciocínio Multi-etapa:** Dificuldade em executar processos que exigem várias etapas encadeadas (ex: diagnóstico seguido de ação) de forma robusta.
- **Interação com Ferramentas:** Desafio na seleção e uso correto de múltiplas APIs; sem orquestração, o LLM não garante a extração correta de contexto ou a escolha apropriada de funções.
- **Dependência Externa:** Para precisão numérica ou dados específicos, há dependência total de bases de conhecimento ou APIs (RAG). Sem isso, a qualidade cai substancialmente.

3. Gestão do Diálogo e Transparência

- **Manutenção de Contexto:** Problemas para preservar o histórico em diálogos multi-turno prolongados, afetando o acompanhamento de casos complexos.
- **Baixa Explicabilidade:** Dificuldade em fornecer caminhos auditáveis sobre o porquê de determinada resposta, o que impede a rastreabilidade necessária para auditorias.

Resultados (EdgeQuake)

Observações Adicionais

Sobre Alternativas: O material indica que arquiteturas estruturadas (STELLAR, pipelines com RAG, escalonamento humano) e abordagens agênticas mitigam essas falhas. Recomenda-se o uso de desenhos controlados (DAG, módulos específicos e checagens de conformidade) para garantir previsibilidade.

Lacunas nos Documentos: Não foram encontradas métricas quantitativas específicas (taxas de erro ou frequências exatas) nos trechos disponibilizados. Os textos descrevem as limitações de forma qualitativa para justificar a necessidade de arquiteturas robustas.

Resultados (Graphify)

Limitações de LLMs Standalone em Customer Support

Baseado na análise do grafo de conhecimento, as principais limitações que emergem do corpus são:

1. Falta de Estrutura e Explicabilidade

O nó central STELLAR propõe uma "Explainable LLM-led architecture", indicando que LLMs standalone carecem de:

- Transparência em decisões de roteamento
- Explicações rastreáveis para escalação de tickets
- Estrutura formal de confiabilidade

2. Necessidade de Escalação Humana

A relação forte entre STELLAR e Human escalation revela que:

- LLMs standalone não conseguem resolver todos os casos automaticamente
- Precisam de mecanismos para identificar quando escalar
- Falta contexto suficiente para decisões críticas

Resultados (Graphify)

3. Limitações de Contexto e Conhecimento
A prevalência de Retrieval-augmented generation (RAG) e Knowledge base refinement mostra:
LLMs standalone ficam limitados ao conhecimento de treinamento
Não conseguem atualizar dinamicamente conhecimento específico do domínio
Necessitam buscar informações externas para tickets complexos

4. Conformidade e Verificação
O nó Compliance verification conectado a STELLAR aponta:
LLMs standalone não garantem conformidade regulatória
Faltam mecanismos auditáveis para rastrear decisões
Precisam de camadas de validação externa

5. Escalabilidade em Ticketing
Soluções como Smart Serve e TickIt propõem AI-driven ticketing intelligence, sugerindo:
LLMs standalone não conseguem gerenciar automaticamente fluxo de tickets
Precisam de orquestração em multi-agent systems
Faltam heurísticas para priorização e roteamento eficiente

Resultados (Notebook LM)

A transição de LLMs puros para arquiteturas estruturadas (como **STELLAR** ou **TickIt**) é motivada por lacunas críticas que impedem o uso direto desses modelos em operações comerciais:

1. Falta de Confiabilidade Factual (Alucinações)

Apesar da fluência linguística, modelos "puros" apresentam problemas graves de consistência. A suscetibilidade a **alucinações** (invenção de fatos) torna o uso direto arriscado em interações sensíveis onde a precisão da informação é inegociável.

2. Baixa Explicabilidade

Existe uma dificuldade inerente em rastrear o "raciocínio" do modelo. A falta de transparência sobre por que uma resposta específica foi gerada dificulta processos de **auditoria, depuração e a construção de confiança** com o usuário final.

3. Deficiência em Raciocínio Complexo e Contexto

Modelos operando de forma isolada frequentemente:

- Perdem o **contexto** em interações longas e prolongadas.
- Falham ao executar processos que exigem **múltiplas etapas** de lógica encadeada de forma robusta.

4. Resultados Imprevisíveis

O suporte ao cliente exige previsibilidade. Depender exclusivamente de capacidades *zero-shot* (diretas) não oferece a consistência necessária para os padrões de qualidade corporativos, resultando em saídas que variam excessivamente em cenários idênticos.

Conclusão

- Superioridade do KG sobre RAG Puro
- Multi-hop permite um melhor raciocínio
- Limitações das Abordagens Data-Driven
- O Papel do SME (Subject Matter Expert)

Conclusão

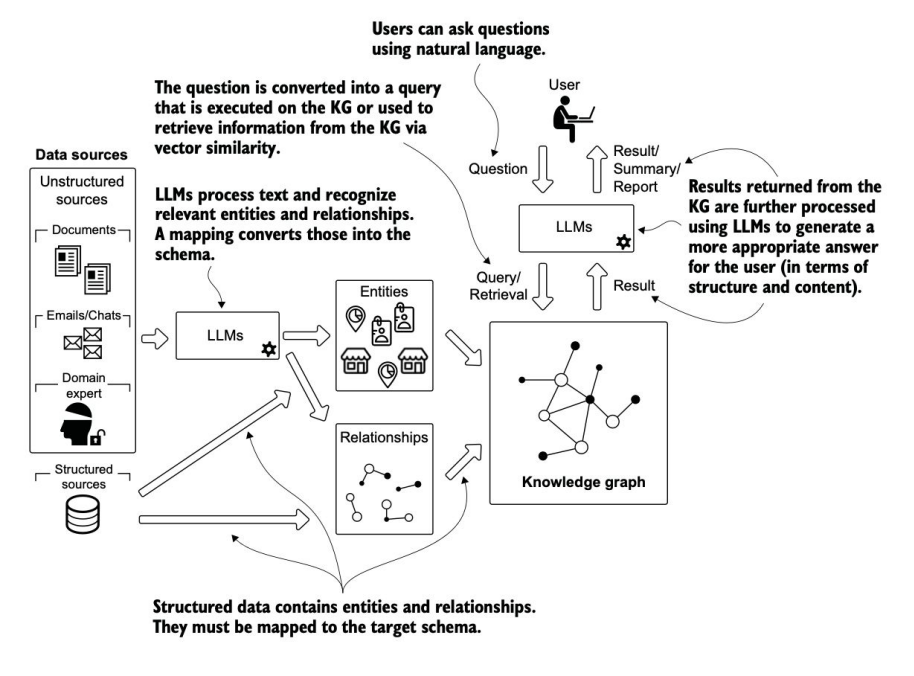

Figura 10: KG query flow. Fonte: GraphRag Microsoft (Versão de Abril/2026)

Referências
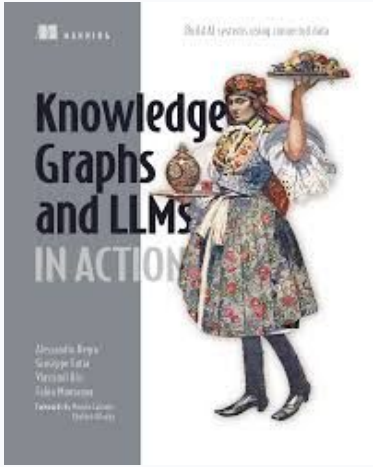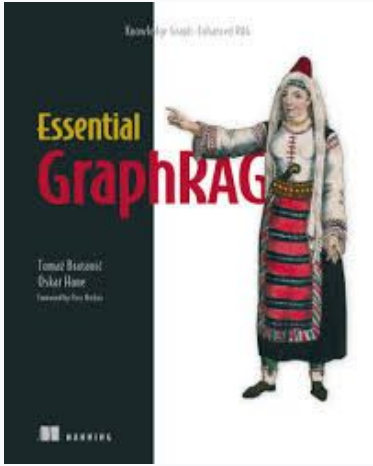
Unifying Large Language Models and Knowledge Graphs: A Roadmap PAN, Shirui et al. Unifying large language models and knowledge graphs: A roadmap. **IEEE Transactions on Knowledge and Data Engineering**, v. 36, n. 7, p. 3580-3599, 2024.